

Previsão de Propriedades ADMET

Recorrendo a Directed Message Passing Neural Network (D-MPNN) Multitarefa



Alunos: Paulo Sérgio Marques Pereira | Matilde Santos

Curso: IA nos Cuidados de Saúde – Perfil de Desenvolvimento

Módulo: Ferramentas de IA Avançado

Professor: Luís Gonçalo

1. Motivação do Problema

A descoberta de novos fármacos é um processo longo, complexo e dispendioso, estimando-se que apenas 1 em cada 5000 moléculas candidatas chegam ao mercado (taxa de aprovação de 5–10%). Uma fase crítica é a caracterização das propriedades ADMET (Absorção, Distribuição, Metabolismo, Excreção e Toxicidade), que determinam a farmacocinética e segurança de um composto. Os ensaios laboratoriais (*in-vitro* ou *in-vivo*) de ADMET são demorados, exigem múltiplos protocolos experimentais distintos e representam um dos principais gargalos do processo de descoberta de fármacos. Existe por isso grande interesse em ferramentas computacionais *in-silico* que permitam estimar previamente estas propriedades com base exclusivamente na estrutura química da molécula, com o maior grau de confiança possível.

Componente	O que avalia
Absorção	Capacidade da molécula penetrar na corrente sanguínea a partir do local de administração
Distribuição	Disseminação pelos tecidos do corpo, incluindo barreiras biológicas como a Barreira Hematoencefálica (BBB)
Metabolismo	Biotransformação molecular, mediada principalmente pelas enzimas do Citocromo P450 (CYP450) hepático, com destaque para a isoforma CYP3A4
Excreção	Eliminação do fármaco e dos seus metabolitos do organismo, sendo a via renal (urina) a mais prevalente
Toxicidade	Avaliação dos efeitos adversos e da segurança global do composto

Para compreender a aplicação prática destes conceitos, usemos um caso prático da morfina como modelo biológico exemplar. Quando administrada por via oral, é absorvida pela mucosa intestinal, distribui-se amplamente pelos tecidos e atravessa a barreira hematoencefálica, garantindo a chegada aos recetores opioides no cérebro e o efeito terapêutico de alívio da dor. É extensamente metabolizada no fígado e eliminada pela urina. A sua toxicidade advém sobretudo da ampla distribuição dos recetores opioides pelo organismo: quando a morfina alcança os pulmões, liga-se a recetores pulmonares e pode causar depressão cardiorrespiratória, colocando o doente em risco de paragem respiratória.

Neste contexto, minimizar os falsos negativos (moléculas com propriedades ADMET desfavoráveis incorretamente classificadas como seguras), é prioritário face à minimização dos falsos positivos. O custo de um falso negativo propaga-se ao longo de todo o pipeline de desenvolvimento, com perdas acumuladas de tempo e recursos. Um falso positivo representa, no limite, a rejeição de um candidato promissor numa biblioteca tipicamente vasta, com impacto comparativamente menor.

2. Abordagem Utilizada

Foi desenvolvida uma Directed Message Passing Neural Network (D-MPNN) multitarefa, capaz de prever simultaneamente 5 *endpoints* ADMET a partir de representações SMILES, combinando 2 tarefas de regressão e 3 de classificação binária num único modelo partilhado. Os dados foram obtidos do *Therapeutics Data Commons* (TDC): Caco-2 Wang (permeabilidade intestinal),

Clearance Hepatocyte AZ (clearance hepática), BBB Martins (penetração na barreira hematoencefálica), CYP3A4 Veith (inibição CYP3A4) e hERG Karim (cardiotoxicidade).

A arquitetura inclui: (i) conversão de SMILES em grafo molecular (átomos = nós, ligações = arestas direcionadas); (ii) *encoder* D-MPNN partilhado para aprender *embeddings* moleculares sem *fingerprints* pré-calculados; (iii) concatenação com 9 descritores RDKit (*MolWeight*, *LogP*, *TPSA*, *HBD*, *HBA*, *RotatableBonds*, *RingCount*, *FractionCSP3*, *FormalCharge*); (iv) duas cabeças independentes, uma de regressão, *RegressionFFN* (Caco-2, Clearance) e outra de classificação, *ClassificationFFN* (BBB, CYP3A4, hERG). O treino usa uma técnica de *masking* binário na função de perda para suportar rótulos ausentes, e *scaffold-balanced split* 80/10/10, para garantir que há uma distribuição equilibrada de moléculas com propriedades diferentes tanto para o treino, validação e teste.

A abordagem conexionista é justificada pela natureza não linear e altamente complexa da relação estrutura-atividade molecular, onde métodos simbólicos ou modelos baseados em descritores pré-definidos (SVM, Random Forest) são inadequados. A D-MPNN aprende padrões diretamente dos dados e generaliza para moléculas não vistas durante o treino.

3. Resultados obtidos

Após 50 épocas de treino (CPU), em conjunto de teste independente (*scaffold-balanced*):

Tarefa	Métrica	Resultado – Teste	Referência (TDC)
Caco-2	RMSE	0.4560	MAE (0.256–6.328)
Caco-2	MAE	0.3610	MAE (0.256–6.328)
Clearance	RMSE	1.1914 (log1p)	Spearman (0.235 – 0.536) Tarefa considerada difícil na literatura (alta variabilidade)
Clearance	MAE	0.9870 (log1p)	Spearman (0.235 – 0.536) Tarefa considerada difícil na literatura (alta variabilidade)
BBB	AUC-ROC	0.8693	AUC-ROC (0.725–0.924)
CYP3A4	AUC-ROC	0.9050	AUP-RC (0.654-0.916)
hERG	AUC-ROC	0.8510	AUC-ROC (0.715–0.880)

Todos os *endpoints* de classificação superaram o critério de aceitabilidade (AUC-ROC > 0.75), com resultados alinhados com os modelos de referência publicados para estes *benchmarks* TDC (0.80–0.92). A Clearance é o *endpoint* mais fraco, consistente com a literatura, sendo intrinsecamente o mais difícil de prever pela variabilidade biológica inerente. Os hiperparâmetros utilizados são todos valores por defeito, com margem significativa para melhoria.

Link para os benchmarks: https://tdcommons.ai/benchmark/admet_group/overview/

4. Potencial aplicação em contexto real

O sistema tem potencial direto como ferramenta de triagem computacional nas fases iniciais de descoberta de fármacos, nomeadamente:

- Triagem virtual de bibliotecas de compostos para filtrar rapidamente milhares de moléculas candidatas antes de síntese ou ensaios laboratoriais, priorizando as com perfil ADMET favorável.
- Otimização de leads, ao orientar a necessidade de modificação estrutural de compostos com propriedades desfavoráveis (ex. baixa permeabilidade Caco-2, risco cardiotoxico por inibição hERG).
- Integração em pipelines de descoberta de novos fármacos, combinar com modelos de eficácia (ex. docking, pIC50) para triagem multiobjectivo.
- Ferramentas como o ADMETlab 3.0 (admetlab3.scbdd.com) utilizam abordagens semelhantes em contexto industrial e académico, validando a relevância da abordagem.

5. Limitações e Melhorias

Os hiperparâmetros utilizados são os definidos por defeito, logo há possibilidade de otimização (ex. *learning rate*, *hidden size*, *depth*, *dropout*) podendo melhorar o desempenho do modelo.

Número de épocas de treino (50) é bastante reduzido. O modelo poderá beneficiar de um treino mais longo, com análise de uma métrica de performance ao longo do treino e com paragem precoce.

O modelo não inclui informação conformacional 3D para a representação das moléculas. Os SMILES/grafos 2D não captam geometria molecular. Modelos 3D (ex. SchNet, DimeNet) poderão capturar padrões adicionais.

Os *datasets* tem uma dimensão relativamente pequena, podendo beneficiar de *data augmentation* ou *transfer learning* para mitigar o impacto.

O modelo por ser uma abordagem conexionista (caixa negra), apresenta interpretabilidade limitada. Os modelos deste género podem usufruir da aplicação de técnicas de XAI (*GNExplainer*, *attention maps*) para explorar a capacidade de explicar as previsões e aumentar a confiança clínica.

A expansão de *endpoints*, incluindo mais propriedades ADMET (solubilidade, ligação a proteínas plasmáticas, semivida), aumentaria a utilidade clínica do sistema, e é algo imprescindível para que o modelo tenha verdadeira aplicabilidade. Este projeto trata-se apenas de uma prova de conceito e exploração do modelo DMPNN e avaliação da viabilidade da abordagem.